

Univerzitet u Nišu,
Elektronski fakultet



Seminarski rad

Tema: Hibridni sistem za preporuku recepata na osnovu sadržaja recepata i analize korisničkih recenzija (**NLP**late)

Predmet: Web mining

Studijski program: Veštačka inteligencija i mašinsko učenje

Mentor: Prof dr Miloš Bogdanović

Student: Anđela Mia Dončov 2152

Sadržaj

1. Uvod.....	3
2. Teorijska osnova	5
2.1 Filtriranje zasnovano na sadržaju (Content-Based Filtering)	5
2.2 Semantičko razumevanje teksta (Sentence-BERT)	5
2.3 Analiza sentimenta korisničkih recenzija (VADER).....	6
2.4 Kvalitet i pouzdanost ocena (Bayes-ov prosek i slaganje)	6
2.5 Hibridni pristup	7
3. Skup podataka i eksplorativna analiza (EDA)	8
3.1 Opis skupa podataka	8
3.2 Preprocesiranje podataka	9
3.3 Eksplorativna analiza podataka (EDA).....	9
4. Arhitektura sistema i implementacija	14
4.1 Priprema teksta i parsiranje preferenci (text_utils.py, preferences.py)	14
4.2 Content-Based komponenta (content_based.py)	14
4.3 Semantička komponenta (semantic.py)	14
4.4 Analiza sentimenta (sentiment.py).....	14
4.5 Kvalitet i slaganje ocena (rating_quality.py)	15
4.6 Hibridni model i povezivanje komponenti sistema (recommender.py).....	15
4.7 Streamlit web aplikacija (app/streamlit_app.py)	15
5. Rezultati i evaluacija.....	17
5.1 Evaluacione metrike i mera relevantnosti.....	17
5.2 Određivanje težinskih koeficijenata.....	17
5.3 Rezultati evaluacije	19
6. Predlog potencijalnih unapređenja i budući rad.....	22
6.1 Skaliranje i brza pretraga	22
6.2 Prava personalizacija i kolaborativno filtriranje	22
6.3 Aspektna analiza recenzija.....	22
6.4 Višejezičnost.....	22
6.5 Prošireni filteri i nutritivni ciljevi	22
6.6 Adaptivno učenje težina.....	23
7. Zaključak.....	24
8. Reference	25

1. Uvod

Razvoj digitalnih kulinarskih platformi i servisa za deljenje recepata, kao što su Food.com, Allrecipes i Yummly, doveo je do značajnog povećanja broja dostupnih recepata i kulinskog sadržaja. Korisnici danas imaju pristup katalozima koji broje stotine hiljada recepata, što sisteme za preporuku čini ključnom komponentom korisničkog iskustva. Bez kvalitetnih preporuka, korisnik je preplavljen izborom i teško pronalazi jelo koje odgovara njegovom trenutnom raspoloženju, načinu ishrane, vremenskim ograničenjima ili konkretnim preferencijama.

Većina postojećih sistema za pretragu recepata zasniva se na jednostavnom pretraživanju ključnih reči i filtriranju prema unapred definisanim atributima. Iako ovakav pristup može brzo pronaći recepte koji ispunjavaju eksplicitno zadate kriterijume, on često ne prepoznaje semantičko značenje korisničkog upita niti koristi informacije iz korisničkih recenzija i ocena za procenu kvaliteta recepata. Kao rezultat, korisnicima se mogu prikazati recepti koji formalno odgovaraju upitu, ali ne zadovoljavaju u potpunosti njihova stvarna očekivanja.

Ovaj seminarski rad opisuje razvoj sistema NLPlate, hibridnog sistema za preporuku recepata koji kombinuje analizu sadržaja recepata, semantičko poređenje korisničkog upita i recepta, analizu sentimenta korisničkih recenzija, kvalitet ocena i slaganje korisnika oko kvaliteta recepta. Za razliku od jednostavnog filtriranja, sistem omogućava korisniku da prirodnim jezikom opiše željeni obrok ili način ishrane, na primer: „I want a quick and healthy chicken dinner with vegetables” ili „I need an easy vegetarian meal with pasta and cheese”. Na osnovu unetog opisa sistem najpre izdvaja skup kandidata koji odgovaraju korisničkom upitu i preferencijama, a zatim ih rangira primenom hibridne funkcije vrednovanja.

Sistem se zasniva na pet komponenti: komponenti zasnovanoj na sadržaju recepta primenom TF-IDF vektorizacije, semantičkom poređenju pomoću Sentence-BERT embeddinga, analizi sentimenta korisničkih recenzija, oceni kvaliteta i pouzdanosti rejtinga, kao i meri slaganja korisnika oko recepta. Navedene komponente kombinuju se pomoću ponderisane sume, čime se dobija finalno vrednovanje preporuke. Kako Burke ističe u svom radu [7], hibridni sistemi se namenski dizajniraju da kombinuju više tehnika preporuke, čime mogu da ublaže ograničenja pojedinačnih pristupa (poput Cold-Start problema) i obezbede robusnije performanse.

Posebna pažnja u radu posvećena je metodološki opravdanom određivanju težinskih koeficijenata. Umesto da se težine zadaju proizvoljno, one se određuju eksperimentalno, tj. pretragom prostora mogućih kombinacija (grid search) i izborom one koja maksimizuje kvalitet rangiranja meren metrikom NDCG (Normalized Discounted Cumulative Gain) nad fiksnim skupom korisničkih upita. Time se obezbeđuje da finalni model bude opravdan podacima, a ne zasnovan na intuiciji.

Skup podataka korišćen u ovom radu je Food.com Recipes and Interactions [9], javno dostupan na platformi Kaggle, koji sadrži 231.637 recepata i 1.132.367 korisničkih recenzija prikupljenih tokom 18 godina interakcija na platformi Food.com. Bogatstvo ovog skupa koje se ogleda u spoju detaljnih metapodataka o receptima i obimne baze korisničkih recenzija sa numeričkim ocenama, omogućava izgradnju sistema koji preporuke zasniva i na sadržaju i na kolektivnom iskustvu korisnika.

U nastavku rada, u drugom poglavlju, biće prikazana teorijska osnova korišćenih algoritama. Treće poglavlje bavi se opisom i preprocesiranjem skupa podataka, uz eksplorativnu (EDA) analizu, dok četvrto poglavlje detaljno opisuje arhitekturu i implementaciju hibridnog sistema. Na kraju, u petom i šestom poglavlju biće predstavljeni rezultati evaluacije, metodologija određivanja težina, kao i predlog potencijalnih unapređenja sistema.

2. Teorijska osnova

Sistemi za preporuku (eng. recommender systems) predstavljaju alate za filtriranje i rangiranje informacija, čiji je cilj da korisniku prikažu stavke koje su najrelevantnije u odnosu na njegove potrebe, preferencije ili trenutni kontekst. Razvijeni su kao odgovor na problem informacionog preopterećenja i danas predstavljaju važan deo brojnih digitalnih servisa. U domenu recepata, izazov je dvostruk: potrebno je razumeti šta korisnik traži, odnosno značenje korisničkog upita i sadržaj recepta, ali i proceniti koliko je recept kvalitetan na osnovu ocena i recenzija zajednice.

2.1 Filtriranje zasnovano na sadržaju (Content-Based Filtering)

Pristup zasnovan na sadržaju koristi karakteristike samih stavki za generisanje preporuka. U domenu recepata, ove karakteristike obuhvataju naziv, sastojke, tagove (kategorije), korake pripreme, nutritivne vrednosti i vreme pripreme. Centralna ideja je transformacija korisničkog upita u isti prostor karakteristika u kom se nalaze i recepti, nakon čega se meri njihova međusobna sličnost. U sistemu NLPlate, za svaki recept formira se sintetizovani tekstualni dokument koji objedinjuje naziv recepta, sastojke, tagove, opis i korake pripreme. Nad ovim dokumentima primenjuje se TF-IDF (Term Frequency – Inverse Document Frequency) [2] vektorizacija, koja svakom terminu dodeljuje težinu srazmernu njegovoj učestalosti u dokumentu, a obrnuto srazmernu njegovoj učestalosti u celom korpusu, čime se naglašavaju informativni, a potiskuju česti termini.

Sličnost između vektora korisničkog upita i vektora svakog recepta meri se kosinusnom sličnošću [3]:

$$\text{sim}(A, B) = \frac{(A \cdot B)}{\|A\| \times \|B\|}$$

Vrednost 1.0 znači da vektori imaju identičan pravac (tekstualni profil recepta savršeno odgovara upitu), dok vrednost 0.0 označava potpuno ortogonalne vektore (nema nikakvog tekstualnog preklapanja u terminima). Pošto su TF-IDF težine nenegativne, kosinusna sličnost se kreće u opsegu [0, 1], što je čini pogodnom za direktnu kombinaciju sa ostalim komponentama hibridnog modela.

2.2 Semantičko razumevanje teksta (Sentence-BERT)

Osnovno ograničenje TF-IDF pristupa je oslanjanje na doslovno preklapanje reči. Upit “quick dinner” i recept opisan kao “easy and fast meal” semantički su veoma bliski, ali ne dele iste reči, pa ih TF-IDF tretira kao slabije povezane. Da bi se prevazišlo ovo ograničenje, NLPlate uvodi semantičku komponentu zasnovanu na modelima tipa Sentence Transformers.

Sentence-BERT [4] predstavlja modifikaciju BERT arhitekture [5] namenjenu efikasnom poređenju rečenica i kraćih tekstova. Model preslikava tekstove u guste vektore fiksne dimenzije, odnosno embeddinge, tako da semantički slični tekstovi budu blizu u vektorskom prostoru. U sistemu NLPlate korišćen je model all-MiniLM-L6-v2, koji tekst enkodira u 384-dimenzionalni vektor. Korisnički upit i tekstualni dokument recepta enkoduju se istim modelom, a njihova bliskost meri se kosinusnom sličnošću. Na taj način sistem može da prepozna sličnost značenja čak i kada se ne koriste identične reči, povezujući izraze kao što su quick dinner, easy meal i simple recipe.

2.3 Analiza sentimenta korisničkih recenzija (VADER)

Numerička ocena (rejting) sama po sebi ne opisuje u potpunosti iskustvo korisnika. Dva recepta sa istom prosečnom ocenom mogu imati veoma različite recenzije: jedan hvaljen zbog jednostavnosti, drugi kritikovan zbog netačnog vremena pripreme. Zato NLPlate analizira i tekstualni sadržaj recenzija. Za analizu sentimenta koristi se VADER (Valence Aware Dictionary and sEntiment Reasoner) [6], leksički alat prilagođen analizi sentimenta u kratkim, neformalnim tekstovima, koji za svaku recenziju generiše tzv. compound vrednost (score) u opsegu $[-1, 1]$.

Compound skorovi svih recenzija jednog recepta se agregiraju (usrednjavaju) i preslikavaju na opseg $[0, 1]$, gde vrednost bliska jedinici označava pretežno pozitivne recenzije. Time se u sistem uvodi dodatni signal kvaliteta zasnovan na jeziku, a ne samo na brojevima. Implementacija predviđa i rezervni (fallback) leksikonski analizator, čime se obezbeđuje rad sistema i u okruženjima gde VADER leksikon nije dostupan.

2.4 Kvalitet i pouzdanost ocena (Bayes-ov prosek i slaganje)

Naivno korišćenje proseka ocena vodi u zabludu: recept sa jednom ocenom 5.0 deluje “bolje” od recepta sa prosečnom ocenom 4.7 i pet stotina recenzija, iako je drugi očigledno pouzdaniji. Da bi se ovaj problem rešio, NLPlate koristi Bayes-ov prilagođen prosek (poznat i kao true Bayesian estimate, isti princip koji koristi IMDb Top lista):

$$BR = \left(\frac{n}{n+m} * R + \frac{m}{n+m} * C \right)$$

gde je R prosečna ocena recepta, n broj njegovih recenzija, C globalni prosek ocena svih recepata, a m “prior” broj recenzija koji određuje koliko snažno se recepti sa malo ocena privlače ka globalnom proseku. Recepti sa malo recenzija se na taj način “vuku” ka C , čime se kažnjava nepouzdanost. Rezultat se normalizuje na opseg $[0, 1]$.

Pored kvaliteta, sistem računa i meru slaganja korisnika (eng. agreement). Ako recept ima veliki broj međusobno sličnih (visokih) ocena, postoji visok nivo saglasnosti da je dobar; ako su ocene

veoma podeljene, sistem ga rangira opreznije. Slaganje se izvodi iz standardne devijacije ocena: niska devijacija znači visoko slaganje. Vrednost se normalizuje i invertuje na opseg [0, 1].

2.5 Hibridni pristup

Hibridni sistemi [7] spajaju prednosti više različitih pristupa kako bi kompenzovali njihova individualna ograničenja. U sistemu NLPlate primenjen je ponderisani (weighted) pristup, gde se finalni skor recepta računa kao linearna kombinacija pet komponenti:

$$final_score = w_1 \cdot content + w_2 \cdot semantic + w_3 \cdot sentiment + w_4 \cdot rating_quality + w_5 \cdot agreement$$

Komponenta *content* predstavlja TF-IDF sličnost između korisničkog upita i tekstualnog dokumenta recepta. Komponenta *semantic* predstavlja semantičku sličnost dobijenu pomoću Sentence-BERT modela. Komponenta *sentiment* opisuje prosečan sentiment korisničkih recenzija. Komponenta *rating_quality* predstavlja Bayes-ov prilagođeni kvalitet ocena, dok *agreement* meri stepen slaganja korisnika oko ocena recepta.

Svaka komponenta daje skor u opsegu [0, 1], pa njihova ponderisana suma ostaje uporediva i interpretabilna. Podrazumevane tj. polazne vrednosti težinskih koeficijenata iznose 0.40 za sadržaj, 0.25 za semantiku, 0.20 za sentiment, 0.10 za kvalitet ocena i 0.05 za slaganje. Te vrednosti predstavljaju samo početnu tačku dok se konačne težine se određuju eksperimentalno (Poglavlje 5). Ukoliko semantička komponenta nije aktivna, njena težina se proporcionalno preraspodeljuje na ostale komponente, čime sistem ostaje funkcionalan.

3. Skup podataka i eksplorativna analiza (EDA)

3.1 Opis skupa podataka

U ovom radu korišćen je Food.com Recipes and Interactions [9], javno dostupan skup podataka sa platforme Kaggle. Skup sadrži 231.637 recepata i 1.132.367 korisničkih recenzija, pokrivajući 18 godina interakcija na platformi Food.com. Za potrebe ovog sistema korišćena su dva osnovna fajla u sirovom (raw) obliku:

- **RAW_recipes.csv** – podaci o receptima (naziv, identifikator, vreme pripreme, sastojci, tagovi, nutritivne vrednosti, koraci pripreme i opis).
- **RAW_interactions.csv** – korisničke interakcije (identifikator korisnika i recepta, datum, numerička ocena i tekstualna recenzija).

Projekat polazi od raw verzije skupa, nakon čega se sprovode čišćenje, transformacija i priprema podataka za modelovanje. U Tabeli 1 prikazani su ključni atributi recepata i njihova uloga u sistemu, a u Tabeli 2 atributi tabele interakcija.

Tabela 1. Pregled ključnih atributa iz RAW_recipes.csv i njihova uloga u sistemu

Atribut	Tip	Opis i uloga u hibridnom sistemu
name	String	Naziv recepta. Koristi se za prikaz i kao deo sintetičkog dokumenta za vektorizaciju.
id	Integer	Jedinstveni identifikator recepta. Ključ za spajanje sa tabelom recenzija.
minutes	Integer	Vreme pripreme u minutima. Koristi se za hard-filtriranje (npr. “brzo”) i kao praktična karakteristika.
tags	Lista	Kategorije i oznake (npr. main-dish, vegetarian, 30-minutes-or-less). Osnova za filtriranje i TF-IDF.
nutrition	Lista	Sedam nutritivnih vrednosti: kalorije, masti, šećer, natrijum, proteini, zasićene masti, ugljeni hidrati (PDV).
n_steps	Integer	Broj koraka pripreme. Indikator složenosti recepta.
steps	Lista	Tekstualni koraci pripreme. Deo dokumenta za vektorizaciju.
description	String	Slobodan opis recepta (opciono). Dodatni izvor za semantičku i tekstualnu sličnost.
ingredients	Lista	Spisak sastojaka. Ključno za filtriranje (željeni/neželjeni sastojci) i sličnost sa upitom.
n_ingredients	Integer	Broj sastojaka. Praktična karakteristika (jednostavnost recepta).

Tabela 2. Atributi tabele interakcija (RAW_interactions.csv)

Atribut	Tip	Opis i uloga u hibridnom sistemu
user_id	Integer	Identifikator korisnika koji je ostavio recenziju.
recipe_id	Integer	Identifikator recenziranog recepta (veza ka RAW_recipes.csv).

Atribut	Tip	Opis i uloga u hibridnom sistemu
date	Date	Datum interakcije.
rating	Integer [0–5]	Numerička ocena. Vrednost 0 najčešće označava recenziju bez ocene i izuzima se iz proseka.
review	String	Tekstualna recenzija. Ulaz za analizu sentimenta.

3.2 Preprocesiranje podataka

Priprema podataka (preprocessing.py) odvija se kroz nekoliko sekvencijalnih koraka:

1. **Parsiranje listi:** kolone tags, ingredients, steps i nutrition u sirovom fajlu zapisane su kao stringovi koji izgledaju kao Python liste; one se bezbedno parsiraju u prave liste, uz toleranciju na neispravne zapise.
2. **Razdvajanje nutritivnih vrednosti:** lista nutrition razlaže se u sedam imenovanih numeričkih kolona (kalorije, masti, šećer, natrijum, proteini, zasićene masti, ugljeni hidrati).
3. **Sinteza tekstualnog dokumenta:** za svaki recept gradi se jedinstvena tekstualna reprezentacija spajanjem (konkatenacijom) naziva, sastojaka, tagova, opisa i koraka. Naziv i sastojci se blago pojačavaju (ponavljaju) jer su najinformativniji za poklapanje sa upitom. Ovaj dokument je zajednički ulaz za TF-IDF i za Sentence-BERT.
4. **Čišćenje:** uklanjaju se recepti bez naziva ili bez sastojaka, kao i duplikati po identifikatoru.
5. **Statistika interakcija:** iz tabele recenzija po svakom receptu računaju se broj recenzija, prosečna ocena i standardna devijacija ocena, kao i broj pozitivnih (≥ 4) i negativnih (≤ 2) ocena.
6. **Izvedene mere kvaliteta:** na osnovu statistike interakcija računaju se Bayes-ov prilagođen prosek (rating_quality) i mera slaganja (agreement), opisane u Poglavlju 2.4.
7. **Agregacija sentimenta:** za svaki recept se iz svih njegovih tekstualnih recenzija računa prosečan sentiment (VADER compound), koji se preslikava na opseg [0, 1].


3.3 Eksplorativna analiza podataka (EDA)

Kroz vizuelnu i statističku analizu obrađenog skupa izvedeni su ključni uvidi koji oblikuju arhitekturu sistema. Svi prikazani rezultati u nastavku su generisani skriptom scripts/00_eda.py nad stvarnim skupom podataka, pri čemu su zbirne statistike sačuvane u fajlu reports/eda_stats.json, a grafici u folderu reports/figures/.

Sirovi skup sadrži 231.637 recepata i 1.132.367 korisničkih interakcija. Nakon čišćenja zadržano je 231.636 recepata, dok recenzije i ocene postoje za 226.590 recepata. Ovaj odnos pokazuje da je skup podataka veoma bogat, ali i da određeni broj recepata nema korisničke recenzije. Upravo

zbog toga u sistemu nije dovoljno koristiti samo prostu prosečnu ocenu, već je potrebno primeniti Bayes-ov prilagođen prosek, koji uzima u obzir i broj recenzija po receptu.

Kao što se vidi na Slici 1, distribucija korisničkih ocena izrazito je nagnuta ka višim vrednostima. Ocene 5 čine 76,19% svih validnih ocena, dok ocene 4 i 5 zajedno čine 93,67% ukupnih ocena. Globalni prosek ocena iznosi 4,6615. Ovakva neuravnoteženost ukazuje na izraženu pristrasnost ka pozitivnim ocenama, što ima direktnu metodološku posledicu: prosta srednja ocena slabo razlikuje recepte, jer je veliki broj recepata ocenjen veoma visoko. Zbog toga se u sistem uvode dodatne mere, kao što su Bayes-ov prilagođen prosek, broj recenzija, slaganje korisnika i sentiment tekstualnih recenzija.




Slika 1. Distribucija korisničkih ocena

Broj recenzija po receptu ima izražen long-tail oblik, što je prikazano na Slici 2. Većina recepata ima mali broj recenzija, dok relativno mali broj popularnih recepata ima veoma veliki broj korisničkih interakcija. Medijana broja recenzija po receptu iznosi 2, prosečan broj recenzija iznosi 4,729, dok maksimalan broj recenzija za jedan recept iznosi 1496. Ovaj nalaz dodatno potvrđuje potrebu za Bayes-ovim prosek, jer recept sa jednom ili dve visoke ocene ne bi trebalo automatski da bude rangiran iznad recepta sa nešto nižom, ali znatno pouzdanijom ocenom zasnovanom na velikom broju korisničkih recenzija.



Slika 2. Raspodela broja recenzija po receptu (logaritamska skala)


Distribucija vremena pripreme, prikazana na Slici 3, pokazuje da se veliki broj recepata nalazi u opsegu kraćih i srednje dugih priprema, dok postoji i rep ka receptima koji zahtevaju znatno više vremena. Medijana vremena pripreme iznosi 40 minuta. Ova karakteristika je važna za korisničko iskustvo, jer korisnici često postavljaju vremenska ograničenja kroz upite kao što su quick dinner ili 30-minute meal. Zbog toga se vreme pripreme u sistemu koristi kao hard-filter kada korisnik eksplicitno zada maksimalno vreme pripreme.



Slika 3. Raspodela vremena pripreme


Raspodela broja sastojaka po receptu prikazana je na Slici 4. Najveći broj recepata ima između približno 6 i 12 sastojaka, dok medijana iznosi 9 sastojaka. Ovaj podatak ukazuje da većina recepata nije ekstremno složena, ali da postoji manji broj recepata sa znatno većim brojem

sastojaka. Broj sastojaka se u ovom radu koristi u eksplorativnoj analizi i kao indikator praktične složenosti recepta, dok se sami sastojci direktno koriste za filtriranje i za izgradnju tekstualnog dokumenta recepta.




Slika 4. Raspodela broja sastojaka po receptu

Analiza tagova, prikazana na Slici 5, pokazuje da su najzastupljeniji tagovi preparation, time-to-make, course, main-ingredient i dietary. Pored njih, često se pojavljuju i tagovi kao što su easy, occasion, cuisine, main-dish, 60-minutes-or-less, meat, 30-minutes-or-less i vegetables. Ovi rezultati pokazuju da tagovi ne opisuju samo tip jela, već i vreme pripreme, težinu recepta, glavne sastojke, kulinarsku kategoriju i dijetetske karakteristike. Zbog toga su tagovi pogodni za filtriranje i kao deo tekstualne reprezentacije recepta.



Slika 5. Dvadeset najčešćih tagova

Korelaciona matrica nutritivnih karakteristika prikazana je na Slici 6. Najizraženije korelacije uočavaju se između ukupnih masti i zasićenih masti (0,90), kalorija i ukupnih masti (0,88), šećera i ugljenih hidrata (0,84), kalorija i ugljenih hidrata (0,83), kao i kalorija i zasićenih masti (0,81). Ovakvi odnosi su očekivani, jer makronutrijenti direktno doprinose energetskej vrednosti recepta. Sa druge strane, pojedine korelacije su znatno slabije, na primer između šećera i proteina (0,14), što pokazuje da nutritivne karakteristike nose različite informacije o receptu. U ovom radu nutritivne vrednosti nisu uključene u finalni skor preporuke, ali rezultati EDA analize pokazuju da bi one mogle predstavljati korisnu osnovu za buduća proširenja sistema, na primer za preporuke prilagođene dijetetskim ili zdravstvenim ograničenjima.



Slika 6. Korelaciona matrica nutritivnih karakteristika

4. Arhitektura sistema i implementacija

Sistem NLPlate implementiran je u programskom jeziku Python kao modularna arhitektura sastavljena od više procesnih modula i interaktivnog Streamlit web interfejsa. Logički tok podataka kroz sistem može se predstaviti sledećim lančanim procesom:

Korisnički upit + preference → Filtriranje kandidata → {Content + Semantic + Sentiment + Rating quality + Agreement} → Hibridni agregator → Top N preporuka sa objašnjenjem

U nastavku su opisani ključni moduli sistema.

4.1 Priprema teksta i parsiranje preferenci (text_utils.py, preferences.py)

Modul za obradu teksta zadužen je za normalizaciju (mala slova, uklanjanje suvišnih karaktera, sažimanje razmaka), bezbedno parsiranje string-reprezentacija listi i sintezu tekstualnog dokumenta recepta. Modul preferenci izvlači “hard” ograničenja iz slobodnog upita: prepozna je željene i neželjene sastojke, maksimalno vreme pripreme i ciljne kategorije (tagove). Na primer, iz upita “quick healthy chicken dinner” automatski se izvode ograničenja: sastojak chicken, kategorija healthy i vremensko ograničenje (“quick” → ≤ 30 min). Ova ograničenja se zatim koriste i za filtriranje i za definisanje relevantnosti pri evaluaciji.

4.2 Content-Based komponenta (content_based.py)

Pri inicijalizaciji se nad sintetizovanim dokumentima receptata konstruiše TF-IDF matrica. Vektorizator je konfigurisan da hvata unigrame i bigrame (ngram_range = (1,2)), filtrira retke termine (min_df=2), ograničava rečnik na 50.000 najvažnijih obeležja, primenjuje logaritamsku normalizaciju učestalosti (sublinear_tf = True) i uklanja engleske stop-reči. Za svaki upit računa se kosinusna sličnost TF-IDF vektora upita sa vektorima receptata. Matrica i vektorizator se računaju jednom i keširaju na disk radi efikasnosti.

4.3 Semantička komponenta (semantic.py)

Semantička komponenta koristi Sentence-BERT model all-MiniLM-L6-v2 koji svaki dokument recepta enkodira u 384-dimenzionalni, L2-normalizovani vektor. Embeddinzi svih receptata računaju se jednom i keširaju u .npy datoteku, jer je njihovo računanje računarski najzahtevniji korak. Pošto su vektori normalizovani, kosinusna sličnost se svodi na skalarni proizvod, pa je rangiranje veoma brzo. Modul je projektovan da radi i u “degradiranom” režimu: ako biblioteka sentence-transformers nije instalirana, semantička komponenta se preskače, a njena težina preraspodeljuje, čime sistem ostaje upotrebljiv.

4.4 Analiza sentimenta (sentiment.py)

Sentiment recenzija računa se VADER analizatorom koji za svaku recenziju vraća compound skor. Skorovi se objedinjuju po receptu i preslikavaju na opseg [0, 1]. Modul ima dvonivovsku

strategiju: primarno koristi NLTK/VADER, a ukoliko on nije dostupan, prelazi na ugrađeni leksikonski analizator sa podrškom za negaciju, čime se garantuje da ceo proces nikada ne prekida rad zbog nedostajuće zavisnosti. Pored prosečnog sentimenta, beleži se i udeo pozitivnih recenzija po receptu.

4.5 Kvalitet i slaganje ocena (rating_quality.py)

Ovaj modul implementira Bayes-ov prilagođen prosek (rating_quality) i meru slaganja (agreement) opisane u Poglavlju 2.4. Globalni prosek C računa se ponderisano brojem recenzija radi stabilnosti, a “prior” m podešen je na 20. Obe mere su isključivo osobine recepta (ne zavise od upita). Računaju se na osnovu prethodno izvedenih statistika interakcija, odnosno broja recenzija, prosečne ocene i standardne devijacije ocena.

4.6 Hibridni model i povezivanje komponenti sistema (recommender.py)

Klasa NLPlateRecommender objedinjuje sve komponente. Proces preporuke teče u nekoliko faza:


1. **Filtriranje kandidata:** primenjuju se hard-filteri iz preferenci. Neželjeni sastojci se isključuju (bezbednost/alergije), dok se ostali filteri (željeni sastojci, kategorije, vreme) po potrebi postupno relaksiraju ako je broj kandidata premali, čime se garantuje da sistem uvek vrati smislen skup.
2. **Formiranje pool-a:** preostali recepti rangiraju se po TF-IDF sličnosti, a u finalno rangiranje ulazi do nekoliko stotina najboljih kandidata.
3. **Računanje komponenti:** za kandidate se izračunavaju sve komponente (content, semantic, sentiment, rating_quality, agreement), svaka u opsegu [0, 1].
4. **Kombinovanje:** komponente se sabiraju ponderisano. Težine se normalizuju da im zbir bude 1; ako semantika nije aktivna, njena težina se preraspodeljuje.
5. **Objašnjivost (Explainability):** za svaku preporuku generiše se ljudski čitljivo objašnjenje koje navodi dominantne razloge (npr. “poklapanje sa upitom” i “pozitivne recenzije”), zajedno sa prosečnom ocenom i brojem recenzija.

Sistem podržava i rad sa istreniranim težinama: ako postoji datoteka sa eksperimentalno određenim koeficijentima, ona se automatski koristi umesto polaznih vrednosti.

4.7 Streamlit web aplikacija (app/streamlit_app.py)

Korisnički interfejs realizovan je u Streamlit okviru i sastoji se od bočnog kontrolnog panela i glavnog ekrana. Bočni panel omogućava unos željenih i neželjenih sastojaka, ograničenje vremena pripreme, izbor kategorija, broj preporuka i izbor režima težina (istrenirane, polazne ili ručno podešavanje slajderima uz prikaz normalizovanih vrednosti). Glavni panel prima slobodan tekstualni upit i prikazuje rezultate u obliku kartica koje sadrže naziv, osnovne informacije

(vreme, ocena, broj recenzija), sastojke, tagove, opis recepta, korake pripreme, objašnjenje preporuke i grafički prikaz doprinosa svake komponente finalnom skor. Računski sloj (TF-IDF indeksi i embeddinzi) inicijalizuje se jednom upotrebom dekoratora `@st.cache_resource`, čime se obezbeđuje brz odziv.



Slika 7. Izgled NLPlate aplikacije

5. Rezultati i evaluacija

5.1 Evaluacione metrike i mera relevantnosti

Evaluacija sistema za preporuku u odsustvu eksplicitnih ljudskih ocena relevantnosti (eng. ground truth) zahteva definisanje posredne (proxy) mere relevantnosti. Food.com skup sadrži interakcije (korisnik, recept, ocena, recenzija), ali ne i ocene relevantnosti za parove (upit, recept). Zato je u ovom radu usvojen pristup u kome se recept smatra relevantnim za upit ako istovremeno zadovoljava dva uslova:

1. Podudaranje sa upitom (na temu): recept zadovoljava “hard” ograničenja izvedena iz upita (željeni sastojci, kategorije, maksimalno vreme pripreme).
2. Kvalitet (pozitivne ocene kao indikator): recept ima dovoljno recenzija i visok Bayes-ov prilagođen prosek ocena.

Drugim rečima, relevantan recept je onaj koji istovremeno “odgovara na temu” i koji je “dokazano dobar”: upravo ono što sistem treba da preporuči. Recept koji odgovara na temu, ali je slabo ocenjen, ne smatra se relevantnim. Za potrebe metrike NDCG, relevantnost je gradirana (0–3) prema kvalitetu: viši Bayes-ov prosek nosi viši stepen relevantnosti, dok recepti bez dovoljno recenzija dobijaju stepen 0 (kvalitet se ne može potvrditi).

Za kvantitativnu ocenu kvaliteta preporuka implementirane su tri standardne metrike za evaluaciju sistema za pronalaženje informacija (modul metrics.py):

- **Precision@K**: udeo relevantnih recepata među prvih K preporučenih.
- **Recall@K**: udeo pronađenih relevantnih recepata u odnosu na sve relevantne (u posmatranom skupu kandidata).
- **NDCG@K (Normalized Discounted Cumulative Gain)** [8]: metrika koja, za razliku od preciznosti, uzima u obzir poziciju preporuke – relevantan recept na vrhu liste donosi veći dobitak nego isti recept niže, uz logaritamsko umanjeње. Koristi gradiranu relevantnost i predstavlja primarnu metriku za izbor težina.

Svi modeli i sve kombinacije težina porede se nad istim, fiksnim skupom od 24 reprezentativna upita u prirodnom jeziku (modul test_queries.py), čime je obezbeđena reproduktivnost.

5.2 Određivanje težinskih koeficijenata

Ključno metodološko pitanje ovog rada jeste kako odrediti težinske koeficijente bez proizvoljnog zadavanja vrednosti. Umesto ručnog zadavanja, primenjen je sledeći postupak (skripta 04_tune_weights.py):

1. Za svaki upit jednom se formira isti skup kandidata i izračunavaju sve komponente koje ulaze u skor. Pošto se vrednosti komponenti računaju jednom po upitu, svaka naredna

kombinacija težina svodi se samo na ponderisani zbir već izračunatih vrednosti, što omogućava efikasnu evaluaciju velikog broja kombinacija.

2. Generiše se simpleks-mreža kombinacija težina pri čemu zbir svih težina mora biti jednak 1. U sistemu je korišćen korak 0,05 i uvedeno je dodatno ograničenje da svaka komponenta mora imati minimalnu težinu 0,05. Ovo ograničenje je uvedeno kako bi se očuvala hibridna priroda sistema, odnosno kako nijedna od pet komponenti ne bi bila potpuno isključena iz finalnog skora.
3. Za svaku kombinaciju računa se prosečan NDCG@10 nad svim upitima.
4. Bira se kombinacija sa najvišim NDCG@10; ona se snima i sistem je na dalje koristi.

Polazne i istrenirane težine prikazane su u Tabeli 3.


Tabela 3. Polazne (iz predloga teme) i eksperimentalno određene težine

Komponenta	Polazna težina	Istrenirana težina
content	0.40	0.05
semantic	0.25	0.05
sentiment	0.20	0.05
rating_quality	0.10	0.80
agreement	0.05	0.05

Rezultati pokazuju da je komponenta rating_quality dobila dominantnu težinu. Ovo je očekivano imajući u vidu način definisanja pseudo-relevantnosti, gde se relevantnim smatra recept koji ne samo da odgovara upitu, već ima dovoljno recenzija i visok Bayes-ov prilagođen kvalitet ocena. Drugim rečima, evaluacija favorizuje recepte koji su istovremeno tematski odgovarajući i pouzdano ocenjeni. Ipak, zahvaljujući uvedenom ograničenju minimalne težine, u finalnom skoru učestvuju i tekstualna sličnost, semantička sličnost, sentiment recenzija i slaganje korisnika, čime se zadržava hibridna struktura modela.

Primarna metrika NDCG@10 za hibridni model sa polaznim težinama iznosila je 0,2129, dok je nakon podešavanja težina dostignuta vrednost 0,6573. Time je ostvareno značajno poboljšanje kvaliteta rangiranja u odnosu na početnu konfiguraciju sistema. Dodatno, Precision@10 je povećan sa 0,2125 na 0,6375, što pokazuje da se među prvih deset preporuka nakon podešavanja težina nalazi znatno veći udeo relevantnih recepata.

Slika 8 pokazuje da eksperimentalno određene težine značajno poboljšavaju sve posmatrane metrike u odnosu na polaznu hibridnu konfiguraciju.




Slika 8. Poređenje hibridnog modela sa polaznim i istreniranim težinama

5.3 Rezultati evaluacije

Da bi se izmerio doprinos pojedinačnih komponenti i hibridnog pristupa, sprovedeno je poređenje više modela nad istim skupom korisničkih upita (skripta 03_evaluate_baselines.py). Evaluirani su: model zasnovan na popularnosti, odnosno rangiranju po kvalitetu ocene (popularity), model zasnovan samo na TF-IDF sličnosti (tfidf), model zasnovan samo na Sentence-BERT semantičkoj sličnosti (sbert), hibridni model sa polaznim težinama (hybrid_baseline) i hibridni model sa eksperimentalno određenim težinama (hybrid_tuned). Rezultati evaluacije za K=10 prikazani su u Tabeli 4 i na Slici 9.

Tabela 4. Poređenje modela (prosek metrika preko upita, K=10)

Model	Precision@10	Recall@10	NDCG@10	Osnovni principi rangiranja
popularity	0,7458	0,0735	0,7365	rangiranje po kvalitetu ocene
tfidf (samo sadržaj)	0,3250	0,0455	0,3350	samo tekstualno poklapanje
sbert (samo semantika)	0,3375	0,0534	0,3301	samo semantička sličnost
hybrid (polazne težine)	0,2125	0,0217	0,2129	polazne težine (baseline)
hybrid (istrenirane težine)	0,6375	0,0638	0,6573	eksperimentalno određene težine



Slika 9. Poređenje modela po metrikama Precision@10, Recall@10 i NDCG@10

Rezultati pokazuju da hibridni model sa eksperimentalno određenim težinama značajno nadmašuje hibridni model sa polaznim težinama. NDCG@10 se povećava sa 0,2129 na 0,6573, dok Precision@10 raste sa 0,2125 na 0,6375. To potvrđuje da izbor težina ima veoma važan uticaj na kvalitet rangiranja i da početne, intuitivno zadate težine nisu bile optimalne za definisanu evaluacionu postavku.


Poređenje sa pojedinačnim komponentama pokazuje da modeli zasnovani samo na tekstualnom ili semantičkom poklapanju ostvaruju znatno slabije rezultate. TF-IDF model postiže NDCG@10 od 0,3350, dok Sentence-BERT model postiže NDCG@10 od 0,3301. Ovi rezultati pokazuju da samo poklapanje sa korisničkim upitom nije dovoljno za kvalitetnu preporuku recepata, jer ne uzima u obzir pouzdanost ocena i iskustvo korisničke zajednice.

Najbolji rezultat prema NDCG@10 ostvaruje model popularity, sa vrednošću 0,7365. Ovaj rezultat je očekivan, jer je pseudo-relevantnost u ovom radu delom definisana preko kvaliteta ocena i broja recenzija. Zbog toga model koji direktno rangira recepte prema rating_quality ima prirodnu prednost u odnosu na modele koji se oslanjaju samo na tekstualnu ili semantičku sličnost. Ipak, takav model ne predstavlja potpun sistem preporuke zasnovan na korisničkom upitu, jer primarno favorizuje recepte koji su generalno dobro ocenjeni, a ne nužno one koji najbolje odgovaraju konkretnim korisničkim preferencijama.

Hibridni model sa istreniranim težinama predstavlja kompromis između kvaliteta ocena i hibridne personalizacije prema upitu. Iako ne nadmašuje potpuno model popularity prema definisanoj pseudo-relevantnosti, on ostvaruje znatno bolje rezultate od TF-IDF, Sentence-BERT i polaznog hibridnog modela, dok istovremeno uključuje sve komponente: sadržaj, semantiku, sentiment, kvalitet ocena i slaganje korisnika. Time se zadržava osnovna ideja sistema NLPlate — preporuke se ne zasnivaju samo na popularnosti, već i na značenju korisničkog upita i dodatnim signalima iz recenzija.

Na Slici 10 prikazane su eksperimentalno određene težine komponenti. Dominantna težina komponente rating_quality pokazuje da je pouzdan kvalitet ocena najvažniji signal u korišćenoj

evaluacionoj postavci. Ostale komponente imaju minimalnu težinu od 0,05, čime ostaju uključene u finalni skor i doprinose očuvanju hibridne prirode modela.



Slika 10. Eksperimentalno određene težine komponenti

Niska vrednost Recall@10 kod svih modela je očekivana, jer se preporučuje samo prvih deset recepata iz veoma velikog kataloga. Kada postoji veliki broj potencijalno relevantnih recepata u skupu kandidata, Recall@10 ostaje relativno nizak čak i kada su preporuke pri vrhu liste kvalitetne. Zbog toga su Precision@10 i NDCG@10 informativnije metrike za procenu kvaliteta rangiranja u ovoj aplikaciji.

6. Predlog potencijalnih unapređenja i budući rad

Iako sistem NLPlate uspešno demonstrira efikasnost hibridnog pristupa, on predstavlja prototip (Proof of Concept) čija se arhitektura može značajno unaprediti. U nastavku su navedene ključne oblasti za nadogradnju.

6.1 Skaliranje i brza pretraga

Trenutni sistem računa sličnost nad celim katalogom u memoriji, što je dovoljno za ovaj skup podataka. Za znatno veće kataloge, TF-IDF i semantičke embeddinge trebalo bi premestiti u specijalizovane indekse za približnu pretragu najbližih suseda (npr. FAISS ili vektorske baze poput Pinecone/Milvus), uz bazu podataka za metapodatke. Time bi se obezbedila brza pretraga kandidata u realnom vremenu nad milionima recepata.

6.2 Prava personalizacija i kolaborativno filtriranje

Najznačajnije unapređenje jeste uvođenje istinske personalizacije. Pošto skup podataka već sadrži stvarne interakcije (korisnik – recept – ocena), moguće je izgraditi punokrvni model kolaborativnog filtriranja zasnovan na faktorizaciji matrice (npr. SVD). Time bi se preporuke prilagodile pojedinačnom korisniku na osnovu njegove istorije, čime sistem prelazi sa čisto upitno-orijentisanog na hibridno personalizovani model.

6.3 Aspektna analiza recenzija

Trenutna analiza sentimenta daje jedan agregatni skor po receptu. Naprednija, aspektno orijentisana analiza (aspect-based sentiment analysis) razdvojila bi mišljenja po dimenzijama – ukus, težina pripreme, tačnost navedenog vremena, isplativost i time omogućila objašnjenja tipa “recept je hvaljen zbog ukusa, ali kritikovan jer traje duže od navedenog”, kao i preciznije rangiranje prema korisničkim prioritetima.

6.4 Višejezičnost

Trenutni NLP moduli (VADER i all-MiniLM-L6-v2) optimizovani su za engleski jezik. Zamenom semantičkog modela višejezičnim ekvivalentom (npr. paraphrase-multilingual-MiniLM-L12-v2), koji mapira preko 50 jezika u isti vektorski prostor, sistem bi mogao da razume upite na srpskom i drugim jezicima (npr. “brza i zdrava večera sa piletinom”) uz očuvanje semantičkog poređenja između upita i recepata.

6.5 Prošireni filteri i nutritivni ciljevi

Korisnički interfejs bi se obogatio granularnijim filterima: nutritivni ciljevi (npr. ograničenje kalorija ili minimum proteina), specifične dijetе (keto, bez glutena), isključivanje alergena, kao i

izbor kuhinje (italijanska, azijska). Pošto su nutritivne vrednosti već izdvojene tokom preprocesiranja, ova proširenja su direktno izvodljiva.

6.6 Adaptivno učenje težina

U trenutnoj verziji težine se određuju jednom (grid search) ili ručno podešavaju. Idealan sistem bi autonomno učio koje težine daju najbolje rezultate za konkretnog korisnika. Primenom algoritama potkrepljenog učenja (npr. Multi-Armed Bandit pristup), sistem bi mogao dinamički pomerati težine na osnovu korisničkih reakcija (klikova, čuvanja recepta), stvarajući individualizovan mehanizam rangiranja.

7. Zaključak

U okviru ovog seminarskog rada projektovan je, implementiran i evaluiran NLPlate, hibridni sistem za preporuku recepata koji kombinuje klasične metode pronalaženja informacija, savremene tehnike obrade prirodnog jezika i mere kvaliteta zasnovane na kolektivnom iskustvu korisnika. Sistem objedinjuje TF-IDF i kosinusnu sličnost, Sentence-BERT semantičko poređenje, VADER analizu sentimenta, Bayes-ov prilagođen prosek ocena i meru slaganja korisnika.

Glavni doprinos rada ogleda se u povezivanju slobodnog korisničkog opisa željenog obroka sa konkretnim receptima, uz istovremeno uvažavanje kvaliteta koji proizilazi iz korisničkih ocena i recenzija. Sistem ne preporučuje recepte samo na osnovu formalnog poklapanja sa upitom, već kombinuje tekstualnu i semantičku sličnost sa signalima pouzdanosti i kvaliteta recepta. Dodatno, ugrađeni mehanizam pojašnjavanja preporuka čini preporuke transparentnijim, jer korisniku prikazuje dominantne razloge preporuke, osnovne informacije o receptu i vrednosti pojedinačnih komponenti skora.

Posebna metodološka vrednost rada ogleda se u načinu određivanja težinskih koeficijenata hibridnog modela. Težine nisu zadate isključivo proizvoljno, već su određene eksperimentalno, pretragom prostora kombinacija i izborom kombinacije koja maksimizuje kvalitet rangiranja prema metrici NDCG@10 nad fiksnim, reproduktivnim skupom upita. Dodatno je uvedeno ograničenje minimalne težine po komponenti, čime je očuvana hibridna priroda sistema i obezbeđeno da svaka komponenta učestvuje u finalnom skor. Rezultati evaluacije pokazali su da podešavanje težina značajno unapređuje kvalitet rangiranja u odnosu na početnu hibridnu konfiguraciju.

Razvijena arhitektura predstavlja dobru osnovu za dalji razvoj. Uvođenjem kolaborativnog filtriranja, detaljnije analize recenzija, podrške za više jezika, nutritivnih filtera i adaptivnog podešavanja težina, sistem bi mogao da daje još personalizovanije preporuke, prilagođene navikama i preferencijama pojedinačnog korisnika.

8. Reference

- [1] G. Adomavicius and A. Tuzhilin, “Toward the Next Generation of Recommender Systems: A Survey of the State-of-the-Art and Possible Extensions,” *IEEE Transactions on Knowledge and Data Engineering*, vol. 17, no. 6, 2005.
- [2] G. Salton and C. Buckley, “Term-weighting approaches in automatic text retrieval,” *Information Processing & Management*, vol. 24, no. 5, 1988.
- [3] C. D. Manning, P. Raghavan, and H. Schütze, *Introduction to Information Retrieval*, Cambridge University Press, 2008.
- [4] N. Reimers and I. Gurevych, “Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks,” in *Proc. EMNLP*, 2019.
- [5] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, “BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding,” in *Proc. NAACL-HLT*, 2019.
- [6] C. J. Hutto and E. Gilbert, “VADER: A Parsimonious Rule-based Model for Sentiment Analysis of Social Media Text,” in *Proc. ICWSM*, 2014.
- [7] R. Burke, “Hybrid Recommender Systems: Survey and Experiments,” *User Modeling and User-Adapted Interaction*, vol. 12, no. 4, 2002.
- [8] K. Järvelin and J. Kekäläinen, “Cumulated gain-based evaluation of IR techniques,” *ACM Transactions on Information Systems*, vol. 20, no. 4, 2002.
- [9] B. P. Majumder, S. Li, J. Ni, and J. McAuley, “Generating Personalized Recipes from Historical User Preferences,” in *Proc. EMNLP*, 2019. (<https://www.kaggle.com/datasets/shuyangli94/food-com-recipes-and-user-interactions>)
- [10] F. Pedregosa et al., “Scikit-learn: Machine Learning in Python,” *Journal of Machine Learning Research*, vol. 12, 2011.
- [11] P. Lops, M. de Gemmis, and G. Semeraro, “Content-based Recommender Systems: State of the Art and Trends,” in *Recommender Systems Handbook*, Springer, 2011.